企业知识库问答 RAG 项目文档

基于 FastAPI、LangChain、Chroma 与 LangGraph 的 RAG + Agent 智能求职助手

版本	1.3	更新日期	2026-10-23	运行环境	Python 3.14

本项目面向企业内部知识管理与求职准备场景。用户可以上传 PDF 文档建立知识库，通过混合检索和带来源引用的问答核验回答；也可以使用 Agent 完成学习计划生成和简历与岗位匹配提示。系统重点验证召回、工具选择、来源可追溯和多轮会话持久化。

10/10	28/30	0.958	10/10
检索 Hit@4	重排后 Hit@1	MRR	拒答正确

1. 当前能力

模块	实现
知识库	上传 PDF 后自动解析、切分、向量化，并重建知识库索引。
混合检索	Chroma + BM25 经加权 RRF 融合，可选 Cross-Encoder 重排。
RAG 问答	返回答案以及文件名、页码、引用片段和检索分数等来源信息。
可靠拒答	没有可靠来源时直接拒答，不调用模型并返回空来源。
Agent 路由	模型自主选择知识检索、学习计划或简历匹配提示工具。
多轮会话	会话写入 SQLite，后端重启后仍可保留最近上下文。
求职功能	支持简历与岗位 JD 匹配、技能缺口分析、学习计划和报告下载。

系统闭环

01	02	03	04
文档上传	**双路召回**	**Agent 路由**	**来源回答**
PDF 解析、切分与重建索引	Chroma + BM25 各取 Top 12	模型选择工具并进入节点	生成答案并返回证据来源

2. 技术栈

层级	技术	用途
接口服务	FastAPI + Uvicorn	提供 HTTP API 与接口文档
流程编排	LangChain + LangGraph	文档处理、状态图、条件路由与可选重排
文档解析	pypdf + PyPDFLoader	提取 PDF 文本与页码
向量数据库	Chroma	保存文档向量和元数据
词法检索	rank-bm25	中文二元分词与 BM25 召回
会话存储	SQLite	持久化多轮会话
模型接口	通义千问 OpenAI 兼容接口	text-embedding-v3 与 qwen-plus
前端	HTML / CSS / JavaScript	知识库、Agent 与简历匹配页面

3. RAG 处理流程

01	**文档导入**	PDF 上传后保存到 data 目录。
02	**文本解析**	PyPDFLoader 提取正文和页码。
03	**文本切分**	500 字符一片，相邻片段重叠 50 字符。
04	**双索引**	生成 Embedding 向量，并为文本片段建立 BM25 索引。
05	**并行召回**	Chroma 与 BM25 各自返回最多 12 个候选片段。
06	**融合与生成**	RRF 后取 Top 4，可选 Cross-Encoder 重排，再由 qwen-plus 生成答案。

4. 检索参数与拒答规则

参数	当前值	说明
切分参数	500 / 50	片段大小 / 相邻重叠字符数
候选 Top K	12 / 12	Chroma 与 BM25 各自候选数
最终 Top K	4	融合后最多返回 4 个片段
RRF	K=10, 1:3	权重 1:3；可选重排 Top 4
相关性阈值（向量）	0.30	低于该值不作为可靠向量证据
上传文件大小限制	10 MB	仅接受 PDF，不支持 Markdown/Word
没有可靠来源时	直接拒答	返回“当前资料中没有找到答案”和空来源

5. LangGraph Agent 工作流

网页统一调用 POST /agent-graph。route 节点先让模型选择一个工具，LangGraph 再通过条件边进入对应节点并执行。旧接口不再维护独立业务逻辑。

节点	工具	职责
route	模型工具选择	根据消息选择工具，并保留参数与路由来源
knowledge	knowledge_search	检索知识库并生成带来源的答案
study	create_study_plan	生成 4 周学习目标、任务和交付物
resume	resume_match_guidance	提示用户上传简历与岗位 JD

6. 评测结果

评测项	结果	说明
检索召回	30/30	扩展集 Hit@4 100%，重排后 Hit@1 93.3%
回答与引用	5/5	答案和引用正确率均为 100%
Agent	5/5	路由和工具选择均由模型完成
无答案拒答	10/10	无答案问题均返回空来源
异常 / 回归	4/4 · 8/8	输入校验与离线测试全部通过

7. 常见问题

为什么回答需要引用来源？
引用让用户能够核对文件名、页码和原文片段，降低模型编造信息的风险。

为什么要使用混合检索？
BM25 补足精确术语，RRF 融合两路结果；需要更高首位命中时可启用 Cross-Encoder。

阈值和 RRF 权重是固定标准吗？
不是。它们基于当前测试语料校准，更换模型或文档分布后必须重新评测。

为什么同名 PDF 不会重复累积向量？
上传后会扫描 data 目录并重建整个 Chroma 集合，因此同名文件会覆盖旧内容。

Agent 如何避免选错工具？
工具描述与系统提示明确约束适用场景；模型未选择工具时，系统使用保守回退并标记 routing=fallback。

8. 当前边界

当前版本仅解析 PDF，尚未实现登录、用户级隔离和多租户权限。Cross-Encoder 默认关闭，本地 CPU 重排约 1.3 秒，生产环境应使用 GPU 或独立服务。阈值、RRF 权重和候选数需随语料重新校准，指标仅代表本地测试。